

Classification des axes thématique pour la production scientifique d'IRG

Ye LIU 23/01/2026

Jeu de données

Source : HAL

Période : articles d'IRG avant 2024

-2486 articles au total, dont 2021 ont au moins un axe

Disciplinary areas:

- Finance and accounting
- Management
- Marketing

Axes thématiques :


AXE1: Performances et responsabilités

AXE2: Société de services et services à la société

AXE3: Innovations, transformations et résistances organisationnelles et sociétales

AXE4: Ouvrages pédagogiques

Répartition des axes thématiques (IRG)



Attentes:

- Compléter automatiquement les métadonnées
- Identifier les thèmes plus spécifiques sous chaque axe et les liens entre les axes

Defis :

- **Manque** : 20 % des données sont manquantes pour les axes.
- **Mutlilabel** : Certaines observations appartiennent à plusieurs axes simultanément
- **Forte imbalance** : axe3 = 42 %, axe1 = 26 %, axe2=22%, axe4= 10%
- **Similarité sémantique** : issus de même domaine 'la gestion'

Traitement du texte

- Embeddings par le model "*BAAI/bge-m3*"

Embedder séparément le titre, les mots-clés, les résumés par le modèle et ajouter un vecteur qui indique la source du texte

Ps. Les 3 colonnes ne sont pas tous disponible dans les articles;
Chaque texte est traité comme un exemple distinct.


Cette approche permet d'augmenter le nombre d'exemples d'apprentissage et de conserver des signaux sémantiques plus spécifiques.

Modèle MLP

- **Données entrées:** Train : 3626 embeddings , 1025+3 dimensions
- **MLP multi-label:** apprend une représentation commune pour prédire plusieurs catégories en même temps.
- **Equilibrer les classes :**
 - **Sampler :** *permet de montrer plus souvent au modèle les exemples des classes rares pendant l'entraînement.*
 - **Focalloss :** *force le modèle à se concentrer davantage sur les exemples difficiles et les classes rares.*
- **Seuil optimisé:** Sélectionné par l'approche 'out of fold', ce qui évite la fuite d'information et limite la surestimation des métriques.

Premier résultat

	precision	recall	f1-score	support
axe1	0.83	0.61	0.70	284
axe2	0.52	0.64	0.58	112
axe3	0.70	0.97	0.81	506
axe4	0.60	0.17	0.26	18



Modèle LR

Un modèle de régression logistique pour prédire l'axe 4, pour éviter la domination des autres axes.

Entraîné **uniquement** sur 1129 embeddings de résumé, qui donne la prédiction la plus performante

	precision	recall	f1-score	support
0.0	1.0000	0.9910	0.9955	222
1.0	0.6667	1.0000	0.8000	4

accuracy			0.9912	226
macro avg	0.8333	0.9955	0.8977	226
weighted avg	0.9941	0.9912	0.9920	226

NB. le nombre d'exemple pour l'axe est très peu, il faut faire attention à sa stabilité.

Résultat final : MLP pour les axes 1-3+LR pour l'axe 4

	precision	recall	f1-score	support
axe1	0.77	0.87	0.82	67
axe2	0.84	0.64	0.72	33
axe3	0.75	0.98	0.85	123
axe4	0.67	1.00	0.80	4
micro avg	0.76	0.89	0.82	227
macro avg	0.76	0.87	0.80	227
weighted avg	0.77	0.89	0.82	227
samples avg	0.81	0.89	0.84	227


F1 micro : 0.8235

F1 macro : 0.7973

F1 weighted : 0.8200


Precision micro : 0.7632

Recall micro : 0.8943



Visualisation

- Chaque point représente un article
- Colorés selon leur(s) axe(s)
 - Si multi-label, les couleurs correspondantes sont superposées sur le même point
- Force d'attraction selon la similarité entre les articles ($w=0.3$)
- Force d'attraction selon l'appartenance à l'axe ($w=0.1$)



Perspectives

- vérifier manuellement les prédictions des axes
- étendre la base de données d'entraînement, afin d'améliorer la stabilité et la précision du modèle.
- réaliser un topic modeling à l'intérieur de chaque axe, pour explorer les thèmes sémantiques spécifiques à chaque axe et analyser les liens thématiques entre les axes.

Merci pour votre attention!